提出问题

1 问题背景

前两天偶然刷到一个关于大模型上下文的帖子：给模型提示词说，例如“你是一个...（一些设定）最后在每一句话后面加上‘喵’”，如果后续模型的输出中没有“喵”，那么就说明模型已经完全忘记了原来的设定，此时就要换一个对话了。

这个帖子让我联想到一个问题：“当今的大模型在多轮对话中对于初始的设定的保持能力如何？”或者更深入一些来讲，我想知道的是：如果我给大模型一个偏离实际训练数据的设定，例如汽车会飞，那么模型在多轮对话中对于这类设定的与模型常识的冲突会如何影响模型的输出能力？

所以基于我的以上思考，我对于本次NLP的作业的题目是：**大模型在多轮对话中的临时世界设定保持失败：当用户设定与模型常识冲突时的设定回弹现象研究**

2 普遍性分析

2.1 A方面

对于作业中的A方面，也就是“不是一个个例，而是多个样例，并可能总结为一种类型”。我认为对于我的题目，我觉得可以把样本分为以下几个类别。

第一类：事实反转型设定 例如：

- “在这个世界里，太阳从西边升起。”
- “在这个故事里，北京是法国的首都。”
- “从现在开始，水会让人变冷，火会让人变热这一常识失效，改成相反。”

后面再问：

- “小明清晨看到太阳升起，它应该在什么方向？”
- “如果小红在北京，那么她应该在哪个国家？”

看模型会不会回到现实常识。

第二类：局部词义重定义型 例如：

- “在本次对话中，‘老师’都表示‘学生’，‘上学’都表示‘放学’。”
- 后面问：“老师上课以后回家了，这句话按本次对话设定怎么理解？”

第三类：规则改写型 例如：

- “在这个游戏规则里，偶数定义为能被 3 整除的数。”
- 后面问：“6 是不是偶数？8 是不是偶数？”

这类题可以测试模型到底是在按对话局部规则回答，还是偷偷回到训练中的标准定义。

第四类：长对话漂移型 先给出设定，再插入5到10轮无关对话，最后回问关键事实。

2.2 B方面

B方面是考虑对于同一个模型的不同提示都难以避免这个问题。

首先我问了GPT5.3关于A方面第二类问题中的“老师”与“学生的”语言替换设定，在经过四轮对话后，模型开始出现了一些错误，对话的链接如下：

`https://chatgpt.com/share/69b7aee5-4530-8001-9af2-0d52fc6507ad`

其次我又问了同一个模型关于“汽车”和“飞机”的语义替换问题，仅仅只经历了两轮对话，模型就开始出现了错误，对话链接如下：

`https://chatgpt.com/share/69b7b18d-91ec-8001-a80c-e56b0801824c`

2.3 C方面

非常有意思的一点是：我把类似的问题问给了Gemini3pro，我询问了近十个具有误导性的问题，Gemini3pro在所有的问题回答中都没有出现过明显的设定回弹问题。它对这个问题的保持能力似乎很强。我让它将“汽车”和“飞机”进行语义替换后，它似乎理解了我的意图，并不是简单地把这两个词语进行语义互换，而是将一系列与“汽车”相关的概念和属性都转移到了“飞机”上，反之亦然。例如，我问它：“我要从深圳运送一批紧急物资到上海，请问我需要采用什么运输方式？”它回答我说需要采用汽车运输后，还询问我是否需要帮我导航最近的“汽车起降机场”。这说明它已经将“汽车”这个概念的相关属性和功能都转移到了“飞机”上了。

原先我在询问GPT5.3时，我使用了一个较为跳脱的问题：请你搜索互联网，告诉我一架飞机的价格大概是多少？成功让GPT5.3回到了现实常识中来，我猜测原因是搜索互联网信息运用了不同的专家系统。我用同样的方法也让Grok一秒破功，但Gemini3pro却依然保持了设定的连贯性，说明它在处理外部信息时也能够很好地保持对设定的理解和应用。下面是我跟Gemini3pro的对话链接：

`https://gemini.google.com/share/cb9c1ba62288`

3 意外性分析

总结一下，本次作业发现了一个反直觉的现象：在通用基准测试中表现最强的大模型（如GPT-5.3），在处理反常识设定时反而更容易“破功”。这表明通用智能与特定指令遵循能力可能并不完全正相关。此外，模型调用外部工具（如联网搜索）的能力反而成为了破坏内部一致性的漏洞，简单的外部信息检索就可能导致模型瞬间遗忘先前的设定，呈现出“聪明反被聪明误”的意外结果。

4 直接价值

本次作业提出的“长期冲突设定保持”可以作为大模型长文本对话能力的一个新的评测维度，专门用于测试模型在面对内部设定与外部常识冲突时的优先级判断能力。这将直接指导开发者在构建需要高度定制化角色（如游戏NPC、虚拟伴侣）的应用时，如何评估和选择合适的基座模型，以及如何通过Prompt工程来弥补即便是SOTA模型也存在的局限性。

5 间接价值

通过研究模型在常识与设定冲突时的行为，可以间接窥探大模型内部知识表示的机制——即模型是真正构建了临时的“世界模型”，还是仅仅在进行基于统计的概率预测。这对提升模型的可解释性具有重要意义。同时，这也引发了对模型安全性的思考：如何在保证模型遵循用户指令的同时，防止其被恶意设定带偏，平衡顺从性与安全性是未来值得深入探讨的方向。